

劳动力调查 AI 助手

成本预算报告（v2）

三档行政层级对照（市级 / 省级 / 国家级）

编制单位：国家统计局贵阳调查队

编制人：刘佳旭

编制日期：2026 年 6 月 22 日

系统版本：v0.1.0（迭代 1 已完成）

测算口径：市级 / 省级 / 国家级 三档，每档人数 $\times$ 月用量匹配，人均月调用 ~ 10 次

目 录

一、摘要

二、部署架构演进

三、单次请求 Token 用量（实测基线）

四、价格基线

五、档位 A：市级（100 人 / 1,000 次/月）

六、档位 B：省级（700 人 / 7,000 次/月） 采购建议档

七、档位 C：国家级（20,000 人 / 200,000 次/月）

八、成本对比表

九、关键风险与合规提示

十、附录 A：价格核对清单

十一、附录 B：已确认价格

十二、采购建议路线图

一、摘要

1.1 三档对照（核心页）

行政层级	人数	月用量	月费	适用场景
市级	100 人	1,000 次	≈ ¥3/月	处室自用（当前架构）
省级 □	700 人	7,000 次	≈ □87/月	采购建议档，市/省级调查队扩展
国家级	20,000 人	200,000 次	≈ ¥1066/月	全省/全国调查员铺开

= 采购建议档：覆盖贵阳调查队当前最可能的下一步扩展（700人市级扩展到省级）。

1.2 成本结构

- API 费用（DeepSeek + DashScope）：纯按量计费，从 ¥2（市级）到 ¥698（国家级）。
- 云资源费用（ECS/域名/SLB/CDN/RDS）：阶梯式，市级 ¥0、省级 ¥62.5、国家级 ¥367.5。

关键观察：省级档云资源占 72%，国家级档云资源占 34%——降本应聚焦云资源选型，API 用量下降对总成本影响有限。

1.3 价格核实状态

服务	价格来源	状态
DeepSeek deepseek-v4-flash	自动抓取 api-docs.deepseek.com	已确认
DashScope text-embedding-v3	训练数据估算	待人工登录核对
阿里云 ECS / 域名 / SLB	训练数据估算	待人工登录核对
阿里云 CDN / RDS	训练数据估算	待人工登录核对
Cloudflare Tunnel	公开文档	已确认免费

修正说明：用户原话为「市级 100 人每月约 1000 次、省级 700 人每月约 7000 次、国家级 2 万人每月约 20 万次」。v1 版本按 3×3 矩阵测算（共 9 档），v2 改为按行政层级划分 3 档——每人月均 ~10 次，符合实际使用习惯。

二、部署架构演进

2.1 三档部署对比

层级	部署方式	关键组件	运维复杂度
市级	本地电脑	FastAPI + Cloudflare Tunnel quick	低（单机）
省级	阿里云单机 ECS	ECS 2核4G + Cloudflare Tunnel named + 域名	中（备案）
国家级	阿里云完整云架构	ECS 4核8G + SLB + CDN + RDS + 域名	高（多组件）

2.2 高并发期（每月 10-16 日，7 天）

数据采集期承担大部分流量，按经验估算：

层级	高并发期 7 天承担比例	高并发期 7 天次数	等效日均
市级	50%	500 次	71 次/天
省级	60%	4,200 次	600 次/天
国家级	70%	140,000 次	20,000 次/天

国家级档高并发期每天 2 万次 $\approx$ 每分钟 14 次（按 8 小时工作日 $\approx$ 每分钟 35 次）。需提前做压力测试。

三、单次请求 Token 用量（实测基线）

来源：backend/app/rag/prompts.py 实测

项	tokens	说明
System prompt	600	固定开销
KB 5 条 × 摘要	1000	每条 ~200 字符中文
用户问题	50	平均 30-50 字
输入小计	1700	
LLM 输出（含 flash reasoning）	300	答案 50-300 字 + thinking 段
输出小计	300	

每千次请求用量：

- 输入：1.7M tokens
- 输出：0.3M tokens
- Embedding：1.7M tokens

四、价格基线

4.1 已自动确认

服务	单价	来源
DeepSeek v4-flash 输入 (cache miss)	\$0.14/M tokens $\approx$ ¥1.0/M	https://api-docs.deepseek.com/quick_start/pricing
DeepSeek v4-flash 输出	\$0.28/M tokens $\approx$ ¥2.0/M	同上
Cloudflare Tunnel (quick / named)	免费	https://developers.cloudflare.com/cloudflare-one/
Let's Encrypt SSL	免费	https://letsencrypt.org

4.2 ☐ 待人工核对

服务	估算价	备注
DashScope text-embedding-v3	¥0.7/M tokens	新用户免费 7000 万 tokens / 90 天
阿里云 ECS t6 (2核4G)	~¥60/月	突发性能实例
阿里云 ECS c7 (4核8G)	~¥300/月	计算型
阿里云 SLB	~¥20/月 + 流量	
.cn 域名	~¥30/年 (折 ¥2.5/月)	
阿里云 CDN (H5 静态)	~¥5/月	H5 单文件, 流量小
阿里云 RDS MySQL	~¥30/月起	反馈数据存储

4.3 单千次请求费用

项	tokens	单价	单千次费用
LLM 输入 (cache miss)	1.7M	¥1.0/M	¥1.70
LLM 输出	0.3M	¥2.0/M	¥0.60
Embedding 输入	1.7M	¥0.7/M	¥1.19
单千次总 API 费			$\approx$ ¥3.49

五、档位 A：市级（100 人 / 1,000 次/月）

5.1 配置

- 部署：本地电脑 + Cloudflare Tunnel quick（与现状一致）
- 运维：用户自己管
- 不需要：ECS、域名、备案、CDN、数据库
- 典型用户：贵阳市劳动力调查处、贵安新区调查队

5.2 费用明细

开销项目	费用
LLM 输入（DeepSeek v4-flash, 1.7M tokens）	¥1.70
LLM 输出（DeepSeek v4-flash, 0.3M tokens）	¥0.60
Embedding（DashScope v3, 1.7M tokens）	¥1.19
Cloudflare Tunnel	免费
ECS	—
域名 + 备案	—
合计	≈ ¥3/月

5.3 风险

- 电脑关机 = 服务下线：本地部署的天然缺陷，适合内部使用不适合外部分发。
- Cloudflare Tunnel quick 域名每次启动变：用户体验差，但对内可用。

5.4 适用判定

- 当前阶段（处室自用）完全够用。
- 升级到省级场景后必须迁云。

六、档位 B：省级（700 人 / 7,000 次/月） □

采购建议档 — 贵阳调查队当前最可能的下一步扩展。

6.1 配置

- 部署：阿里云 ECS（2核4G 突发 t6）+ Cloudflare Tunnel named + 自有域名
- 域名备案：政府单位走阿里云 ICP 备案系统（约 15-20 工作日，免费）
- HTTPS：Let's Encrypt 自动续期
- 不需要：SLB（单机够用）、CDN（H5 体积小）、RDS（feedback.jsonl 暂存本地）
- 典型用户：贵州省劳动力调查队、贵阳市调查队 + 各区县调查队

6.2 费用明细

开销项目	费用
LLM 输入（11.9M tokens）	¥11.90
LLM 输出（2.1M tokens）	¥4.20
Embedding（11.9M tokens）	¥8.33
ECS（2核4G t6）	¥60
.cn 域名（年付折月）	¥2.5
ICP 备案	一次性免费
Cloudflare Tunnel named	免费
SSL 证书	免费
合计	≈ ¥87/月

6.3 风险

- 域名备案流程 15-20 工作日：提前启动，不能临到用时再备。
- ECS 单点故障：突发实例性能有限，重要场景考虑升级到 c7（4核8G）月费 ¥300。
- 反馈数据存本地：省级用户量大时建议上云数据库。

6.4 高并发期表现

高并发期 7 天承担 60% 流量 = 每天 ~600 次（按 8 小时工作日 ≈ 每分钟 1.25 次）。单 ECS 2核4G 跑 DeepSeek 转发绰绰有余（瓶颈在 DeepSeek 端 QPS 限额，不在本机）。

6.5 采购建议

- 月度预算：¥87/月 ≈ ¥1,044/年
- 一次性投入：域名 ¥30 + 备案工时（无需费用）

- 可走采购流程：政府采购协议供货，单价 < ¥100/月通常走小额采购或协议供货

七、档位 C：国家级（20,000 人 / 200,000 次/月）

7.1 配置

- 部署：阿里云 ECS（4核8G 计算型 c7）+ SLB + Cloudflare Tunnel named + 域名 + 备案
- CDN：H5 静态资源走阿里云 CDN（按流量计费）
- 向量库升级：Chroma → 独立服务（Milvus 或 Zvec 备选）
- 数据库：用户反馈数据上云数据库 RDS（按量计费）
- 典型用户：全国调查员（铺开到国家统计局层面）

7.2 费用明细

开销项目	费用
LLM 输入（340M tokens）	¥340.00
LLM 输出（60M tokens）	¥120.00
Embedding（340M tokens）	¥238.00
ECS（4核8G c7）	¥300
SLB（含流量）	¥30
.cn 域名	¥2.5
CDN（H5 静态）	~¥5
RDS MySQL（反馈数据）	¥30
ICP 备案	一次性免费
Cloudflare Tunnel named	免费
合计	≈ ¥1066/月

7.3 风险

- 高并发期每天 2 万次 ≈ 每分钟 14-35 次：4核8G 单机压力测试需做，极端情况需双 ECS + SLB 横向扩展（月费翻倍至 ¥1500+）。
- 向量库升级：Chroma 嵌入式模式在国家级规模不够用，详见项目 `memory_zvec_alternative.md`
- API QPS 限额：DeepSeek 默认并发 2500，国家级档完全够用；如未来升至亿级需要走商务谈判。
- 数据合规：覆盖全国时居民个人信息合规审查必须前置。

7.4 采购建议

- 月度预算：¥1066/月 ≈ ¥12,792/年

- 采购流程：超 ¥500/月通常走政府采购公开招标
- 建议路径：先用省级档（¥87/月）跑半年，验证稳定后再升级到国家级

八、成本对比表

层级	人数	月用量	API 费	云资源	月费合计	年费	人均年成本
市级	100	1,000	¥3.49	¥0	¥3	¥40	¥0.40/人/年
省级 □	700	7,000	□24.43	□62.5	□87	□1,044	□1.49/人/年
国家级	20,000	200,000	¥698.00	¥367.5	¥1066	¥12,792	¥0.64/人/年

= 采购建议档

8.1 成本结构观察

层级	API 占比	云资源占比	主要降本杠杆
市级	100%	0%	不需要降本
省级	28%	72%	降云资源（选 ECS 规格、用包年优惠）
国家级	66%	34%	降API（用 deepseek-v4-pro 比 flash 贵 3 倍，反而应该往更便宜的模型走）

8.2 人均年成本观察

省级档人均成本最高（每人 1.49 元/年），因为 ECS 固定成本分摊人数少。

国家级档反而人均成本低（每人 0.64 元/年），规模效应明显。

九、关键风险与合规提示

9.1 数据合规（最高优先级）

居民个人信息禁止上云：本系统当前架构（H5 不接触调查数据，仅返回 RAG 答案）已遵守。

系统架构严格隔离：H5 → 后端 API → 阿里云百炼 / DeepSeek（仅传查询文本，不存个人数据）。

国家级档覆盖全国时，采购合同中必须明确数据流向和隐私承诺。

9.2 政府采购流程

- 云资源按月租 $\geq$ 一定金额通常走政府采购或协议供货
- 域名备案：政府/事业单位域名必须备案，流程约 15-20 工作日
- API Key 管理：DeepSeek/DashScope 账号开在单位名下而非个人
- ¥87/月（省级档）属小额采购或协议供货范畴，流程相对简单

9.3 量纲校验

修正后三档人均月调用都 ≈ 10 次，完全符合实际使用习惯（处室每人每天不到 1 次，省级每人每周 2-3 次，国家级每人每周 2-3 次）。

之前 v1 的 3×3 矩阵中异常档（如 100 人 $\times$ 20 万次 = 每人每天 67 次）已删除。

9.4 技术演进路径

- 省级档向量库：Chroma 嵌入式 + BM25 hybrid 当前够用，无需升级
- 国家级档向量库：建议提前评估 Zvec（阿里通义实验室 2026-02 开源，详见项目 memory zvec_alternative.md）
- 稳定性增强：省级档从 Cloudflare Tunnel quick 切 named tunnel（已规划）；国家级档考虑 SLB + 多 ECS 横向扩展

十、附录 A：价格核对清单

以下服务因登录墙/JS 渲染，自动脚本无法获取精确价格。请采购前登录核对：

#	服务	核对路径	期望价格	实际价格（请填）
1	DashScope text-embedding	https://dashscope.console.aliyun.com/billing	¥0.7/M tokens	待填
2	阿里云 ECS t6（2核4G）	https://www.aliyun.com/product/ecs → 突发性能	~¥60/月	待填
3	阿里云 ECS c7（4核8G）	同上 → 计算型	~¥300/月	待填
4	阿里云 SLB	https://www.aliyun.com/product/slb	~¥20/月 + 流量	待填
5	.cn 域名	https://wanwang.aliyun.com	~¥30/年	待填
6	阿里云 CDN	https://www.aliyun.com/product/cdn	~¥0.24/GB	待填
7	阿里云 RDS MySQL	https://www.aliyun.com/product/rds/mysql	~¥30/月起	待填

十一、附录 B：已确认价格

#	服务	实际价格	来源
1	DeepSeek v4-flash 输入（cache miss）	\$0.14/M tokens ≈ ¥1.01/M	api-docs.deepseek.com/quick_start/pricing
2	DeepSeek v4-flash 输出	\$0.28/M tokens ≈ ¥2.0/M	同上
3	DeepSeek v4-flash 输入（cache hit）	\$0.0028/M ≈ ¥0.02/M（不适用本场景）	同上
4	Cloudflare Tunnel	免费	developers.cloudflare.com
5	Let's Encrypt SSL	免费	letsencrypt.org

十二、采购建议路线图

下一步演进路径（市级 → 省级 → 国家级）：

当前（迭代 1 已完成）

- 市级档：本地电脑 + Cloudflare Tunnel quick
 - 月费 3/月 (API only)
- ↓ 用户量增长到 700 人 / 7000 次/月

省级档（采购建议）

- 阿里云 ECS 2核4G + 域名 + 备案
 - 月费 87/月
 - 采购流程：协议供货 / 小额采购
 - 启动准备：域名备案 15-20 工作日
- ↓ 覆盖到全国调查员

国家级档

- 阿里云 ECS 4核8G + SLB + CDN + RDS
 - 月费 1066/月
 - 采购流程：政府采购公开招标
 - 启动准备：向量库升级 (Chroma → Zvec/Milvus)、压力测试、合规审查

— 报告结束 • 本表可作为采购可行性报告附件提交 —